

Analyse de Prix par Régression Quantile - Marché du Thé

Présentation Stage

2025-07-10

① Introduction et Objectifs

Plan de la Présentation

- ➊ Introduction et Objectifs
- ➋ Statistiques Descriptives

Plan de la Présentation

- ➊ Introduction et Objectifs
- ➋ Statistiques Descriptives
- ➌ Préparation des Données

Plan de la Présentation

- ➊ Introduction et Objectifs
- ➋ Statistiques Descriptives
- ➌ Préparation des Données
- ➍ Méthodologie : Régression Quantile

Plan de la Présentation

- ➊ Introduction et Objectifs
- ➋ Statistiques Descriptives
- ➌ Préparation des Données
- ➍ Méthodologie : Régression Quantile
- ➎ Résultats par Région

Plan de la Présentation

- ➊ Introduction et Objectifs
- ➋ Statistiques Descriptives
- ➌ Préparation des Données
- ➍ Méthodologie : Régression Quantile
- ➎ Résultats par Région
- ➏ Conclusions et Recommandations

1. Introduction et Objectifs

Contexte

- Analyse du marché mondial du thé

Objectifs

1. Introduction et Objectifs

Contexte

- Analyse du marché mondial du thé
- Compréhension des facteurs de prix

Objectifs

1. Introduction et Objectifs

Contexte

- Analyse du marché mondial du thé
- Compréhension des facteurs de prix
- Différenciation par régions géographiques

Objectifs

1. Introduction et Objectifs

Contexte

- Analyse du marché mondial du thé
- Compréhension des facteurs de prix
- Différenciation par régions géographiques

Objectifs

- Identifier les déterminants du prix du thé

1. Introduction et Objectifs

Contexte

- Analyse du marché mondial du thé
- Compréhension des facteurs de prix
- Différenciation par régions géographiques

Objectifs

- Identifier les déterminants du prix du thé
- Analyser les variations par quantiles de prix

1. Introduction et Objectifs

Contexte

- Analyse du marché mondial du thé
- Compréhension des facteurs de prix
- Différenciation par régions géographiques

Objectifs

- Identifier les déterminants du prix du thé
- Analyser les variations par quantiles de prix
- Comparer les marchés régionaux

2. Statistiques Descriptives

Aperçu Global des Données

```
# Nettoyage de l'environnement
```

```
rm(list = ls())
```

```
# Instalation et chargements des packages necessaires
```

```
if (!require("ggrepel")) install.packages("ggrepel")
```

```
library(readxl)
```

```
library(tidyverse)
```

```
library(dplyr)
```

```
library(lubridate)
```

```
library(wordcloud)
```

```
library(tidytext)
```

```
library(scales)
```

```
library(ggplot2)
```

```
library(gganimate)
```

```
library(gridExtra)
```

2. Statistiques Descriptives (suite)

Évolution des Lancements dans le Temps

```
# Nombre de lancements par mois
df %>%
  count(month) %>%
  ggplot(aes(x = month, y = n)) +
  geom_line(color = "steelblue", size = 1) +
  labs(title = "Lancements de produits par mois (1998-2025)",
       x = "Année",
       y = "Nombre de produits lancés",
       caption = "Source: Base Mintel GNPD") +
  theme_minimal()
```


2. Statistiques Descriptives (suite)

Top Marchés de Lancement

```
# Top 10 des marchés de lancement
```

```
p1 <- df %>%  
  filter(year >= 2010) %>%  
  count(Market, sort = TRUE) %>%  
  slice_max(n, n = 10) %>%  
  ggplot(aes(x = reorder(Market, n), y = n)) +  
  geom_col(fill = "darkgreen") +  
  coord_flip() +  
  labs(title = "Top 10 des marchés de lancement (2010+)",  
       x = "Marché",  
       y = "Nombre de lancements",  
       caption = "Source : Base Intel")
```

```
p2 <- df %>%  
  filter(year >= 2020) %>%
```

2. Statistiques Descriptives (suite)

Répartition par Famille de Produits

Répartition des sous-catégories

```
p1 <- df %>%  
  count(`Sub-Category`, sort = TRUE) %>%  
  slice_max(n, n = 10) %>%  
  ggplot(aes(x = reorder(`Sub-Category`, n), y = n)) +  
  geom_col(fill = "tomato") +  
  coord_flip() +  
  labs(title = "Top 10 des sous-catégories",  
       x = "Sous-catégorie",  
       y = "Nombre de produits",  
       caption = "Source : Mintel")
```

```
p2 <- df %>%  
  count(`Famille thé`, sort = TRUE) %>%  
  ggplot(aes(x = reorder(`Famille thé`, n), y = n)) +
```

2. Statistiques Descriptives (suite)

Évolution des Lancements par Famille

Évolution annuelle par famille de thé

```
evolution_data <- df %>%  
  count(year, `Famille thé`) %>%  
  group_by(`Famille thé`) %>%  
  mutate(  
    last_year = (year == max(year)),  
    label = if_else(last_year, `Famille thé`, NA_character_)  
  )  
  
ggplot(evolution_data, aes(x = year, y = n, color = `Famille t  
  geom_line(linewidth = 1.2, alpha = 0.8) +  
  geom_point(size = 3, alpha = 0.8) +  
  geom_label_repel(  
    aes(label = label),  
    na.rm = TRUE,
```

2. Statistiques Descriptives (suite)

Analyse des Prix

```
# Nettoyage des données de prix (99% des produits)
```

```
df_clean <- df %>%
```

```
  filter(!is.na(`Price per 100 g/ml in Euros`),
```

```
         `Price per 100 g/ml in Euros` < quantile(`Price per 1
```

```
# Statistiques descriptives des prix
```

```
df_clean %>%
```

```
  summarise(
```

```
    min_price = min(`Price per 100 g/ml in Euros`, na.rm = TRUE)
```

```
    mean_price = mean(`Price per 100 g/ml in Euros`, na.rm = TRUE)
```

```
    median_price = median(`Price per 100 g/ml in Euros`, na.rm = TRUE)
```

```
    max_price = max(`Price per 100 g/ml in Euros`, na.rm = TRUE)
```

```
    sd_price = sd(`Price per 100 g/ml in Euros`, na.rm = TRUE)
```

```
    n = n()
```

```
)
```

2. Statistiques Descriptives (suite)

Prix par Famille de Produits

Boxplot des prix par famille de thé

df %>%

```
filter(!is.na(`Price per 100 g/ml in Euros`),  
       `Price per 100 g/ml in Euros` < 100) %>%
```

```
group_by(`Famille thé`) %>%
```

```
filter(n() >= 10) %>%
```

```
ggplot(aes(x = reorder(`Famille thé`, `Price per 100 g/ml in Euros`),  
           y = `Price per 100 g/ml in Euros`)) +
```

```
geom_boxplot(fill = "orange") +
```

```
coord_flip() +
```

```
labs(title = "Prix par famille de thé",
```

```
     x = "Famille de thé",
```

```
     y = "Prix par 100g/ml (€)",
```

```
     caption = "Source : Mintel") +
```

```
theme_minimal()
```

2. Statistiques Descriptives (suite)

Claims Marketing les Plus Fréquents

```
# Extraction des claims individuels
```

```
claims <- df %>%  
  filter(!is.na(`Positioning Claims`)) %>%  
  unnest_tokens(claim, `Positioning Claims`, token = "regex",  
  count(claim, sort = TRUE)
```

```
# Top 15 des claims les plus fréquents
```

```
claims %>%  
  slice_max(n, n = 15) %>%  
  ggplot(aes(x = reorder(claim, n), y = n)) +  
  geom_col(fill = "purple") +  
  coord_flip() +  
  labs(title = "Principaux arguments marketing",  
    x = "Claim",  
    y = "Fréquence",
```

2. Statistiques Descriptives (suite)

Prix selon les Claims Marketing

```
# Séparation des claims en lignes individuelles
```

```
df_long <- df %>%  
  filter(!is.na(`Positioning Claims`)) %>%  
  separate_rows(`Positioning Claims`, sep = ",\\s*")
```

```
# Top 15 claims avec le prix médian le plus élevé
```

```
top_claims <- df_long %>%  
  group_by(`Positioning Claims`) %>%  
  summarise(median_price = median(`Price per 100 g/ml in Euros`))  
  arrange(desc(median_price)) %>%  
  slice_head(n = 15) %>%  
  pull(`Positioning Claims`)
```

```
# Boxplot des claims les plus chers
```

```
df_long %>%
```

2. Statistiques Descriptives (suite)

Analyse des Emballages

```
# Top 20 des types d'emballage
```

```
df %>%
```

```
  filter(!is.na(`Package Type`)) %>%
```

```
  count(`Package Type`, sort = TRUE) %>%
```

```
  slice_max(n, n = 20) %>%
```

```
  ggplot(aes(x = reorder(`Package Type`, n), y = n)) +
```

```
  geom_col(fill = "darkred") +
```

```
  coord_flip() +
```

```
  labs(title = "Top 20 des types d'emballage",
```

```
        x = "Type d'emballage",
```

```
        y = "Nombre de produits",
```

```
        caption = "Source : Mintel") +
```

```
  theme_minimal()
```

```
# Top 20 des matériaux d'emballage
```


2. Statistiques Descriptives (suite)

Prix selon le Type d'Emballage

```
# Prix selon le matériau d'emballage
df %>%
  filter(!is.na(`Package Material`),
         `Price per 100 g/ml in Euros` <= quantile(`Price per
ggplot(aes(x = fct_lump(`Package Material`, 10),
          y = `Price per 100 g/ml in Euros`)) +
  geom_boxplot(fill = "#f4a261") +
  labs(title = "Prix selon le matériau d'emballage",
       x = "Matériau d'emballage",
       y = "Prix pour 100g/ml (€)",
       caption = "Source : Mintel") +
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +
  theme_minimal()

# Prix selon le type d'emballage
```

3. Préparation des Données

Importation et Nettoyage

```
# Nettoyage de l'environnement
```

```
rm(list = ls())
```

```
# Packages nécessaires
```

```
library(readxl)
```

```
library(tidyverse)
```

```
library(dplyr)
```

```
library(lubridate)
```

```
library(quantreg)
```

```
# Importation des données
```

```
df1 <- read.csv("df_pib.csv")
```

```
df2 <- read.csv("df_prod_tea.csv")
```

```
df <- read_excel("GNPD_tea.xlsx")
```

2. Préparation des Données (suite)

Création des Variables Régionales

```
# Création de la variable région
```

```
df <- df %>%
```

```
  mutate(
```

```
    Region_Marche = case_when(
```

```
      Market %in% c("China", "Japan", "South Korea", "Taiwan",  
                    "Hong Kong,China", "Vietnam", "Thailand",  
                    "Malaysia", "Philippines", "Singapore", "M  
                    "Cambodia", "Laos", "Sri Lanka", "India", "Ba  
                    "Hong Kong, China") ~ "Asie",
```

```
      Market %in% c("UK", "France", "Germany", "Italy", "Spain",  
                    "Switzerland", "Netherlands", "Belgium", "  
                    "Denmark", "Norway", "Finland", "Austria",  
                    "Greece", "Portugal", "Ireland", "Luxembou  
                    "Czech Republic", "Slovakia", "Slovenia",  
                    "Latvia", "Lithuania", "Hungary", "Romania
```

2. Préparation des Données (suite)

Création des Claims Marketing

```
# Claims santé
```

```
claims_sante <- c(
```

```
  "Antioxydant", "Functional - Energy", "Functional - Slimming",  
  "Functional - Immune System", "Functional - Brain & Nervous",  
  "Functional - Cardiovascular", "Functional - Digestive",  
  "Functional - Bone Health", "Functional - Stress & Sleep",  
  "Functional - Beauty Benefits", "Functional - Skin",  
  "Functional - Eye Health", "Functional - Weight & Muscle Gain",  
  "Anti-Ageing", "Nails & Hair", "Vitamin/Mineral Fortified",  
  "High/Added Fibre", "High/Added Protein", "Added Calcium",  
  "Prebiotic", "Probiotic", "Stanols/Sterols", "Whitening",  
  "Breath-Freshening", "High Satiety", "Low/No/Reduced Transfat",  
  "Low/No/Reduced Glycemic", "Low/No/Reduced Saturated Fat",  
  "Low/No/Reduced Carb", "Low/No/Reduced Cholesterol",  
  "Low/No/Reduced Lactose", "Low/No/Reduced Allergen"
```

2. Préparation des Données (suite)

Fonction de Détection des Claims

Fonction pour détecter la présence d'un mot-clé

```
detect_claim <- function(text, keywords) {  
  if (is.na(text)) return("non")  
  any(str_detect(text, fixed(keywords, ignore_case = TRUE)))  
}
```

Créer les colonnes

```
df <- df %>%  
  mutate(  
    claim_sante = map_chr(`Positioning Claims`, ~ detect_claim(  
    claim_naturel = map_chr(`Positioning Claims`, ~ detect_claim(  
    claim_ethique = map_chr(`Positioning Claims`, ~ detect_claim(  
    claim_strategie = map_chr(`Positioning Claims`, ~ detect_claim(  
    claim_ciblage = map_chr(`Positioning Claims`, ~ detect_claim(  
    claim_bio = map_chr(`Positioning Claims`, ~ detect_claim(  
  )
```

2. Préparation des Données (suite)

Catégorisation des Produits et Packaging

```
# Création de la famille thé
```

```
df <- df %>%
```

```
  mutate(`Famille thé` = case_when(
```

```
    `Sub-Category` == "Tea" ~ "Thé",
```

```
    `Sub-Category` == "RTD (Iced) Tea" ~ "Thé prêt à boire",
```

```
    `Sub-Category` %in% c("Kombucha & Other Fermented Drinks",
```

```
      "Flavoured Water", "Beverage Mixes",
```

```
      "Beverage Concentrates", "RTD (Iced)
```

```
      "Energy Drinks", "Flavoured Water",
```

```
      "Flavoured Alcoholic Beverages", "Win
```

```
      "Carbonated Soft Drinks", "Vodka", "Li
```

```
      "Juice", "Coffee", "Beer", "Malt & Othe
```

```
      "Fruit/Flavoured Still Drinks", "Drin
```

```
      "Nectars", "Plant Based Drinks (Dairy
```

```
      "Flavoured Milk",
```

3. Méthodologie : Régression Quantile

Principe de la Régression Quantile

La régression quantile permet d'estimer les effets des variables explicatives sur différents quantiles de la distribution de la variable dépendante (prix), contrairement à la régression linéaire classique qui ne modélise que la moyenne.

Avantages

- **Robustesse** : Moins sensible aux valeurs extrêmes

3. Méthodologie : Régression Quantile

Principe de la Régression Quantile

La régression quantile permet d'estimer les effets des variables explicatives sur différents quantiles de la distribution de la variable dépendante (prix), contrairement à la régression linéaire classique qui ne modélise que la moyenne.

Avantages

- **Robustesse** : Moins sensible aux valeurs extrêmes
- **Flexibilité** : Capture les variations à différents niveaux de prix

3. Méthodologie : Régression Quantile

Principe de la Régression Quantile

La régression quantile permet d'estimer les effets des variables explicatives sur différents quantiles de la distribution de la variable dépendante (prix), contrairement à la régression linéaire classique qui ne modélise que la moyenne.

Avantages

- **Robustesse** : Moins sensible aux valeurs extrêmes
- **Flexibilité** : Capture les variations à différents niveaux de prix
- **Interprétation** : Comprendre les déterminants selon les segments de prix

3. Méthodologie (suite)

Modèle Global pour le Thé

```
df_tea <- df %>%  
  filter(`Sub-Category` == "Tea")  
  
# modele  
model_tea <- rq(`Price per 100 g/ml in Euros` ~ Region_Marche  
  `Private Label`+claim_sante+claim_ethique+cl  
  claim_strategie+claim_naturel+package_group_t  
  claim_bio+ claimenvironnement+ pib_categorie  
  data = df_tea,  
  tau = c(0.25,0.5,0.75))  
  
summary(model_tea, se="ker")
```

Note : se="ker" utilise la méthode kernel, recommandée pour les grands échantillons.

4. Résultats par Région

Marché Européen

Modèle pour l'Europe

```
model_tea_europe <- rq(`Price per 100 g/ml in Euros` ~ `Launch`  
  `Private Label` + claim_sante + claim_naturel + claim_strategie + claim_naturel + pack_size +  
  claim_bio + claimenvironnement + pib  
  data = df_tea %>%  
    filter(trimws(Region_Marche) == "Europe")  
  tau = c(0.25, 0.5, 0.75))  
  
summary(model_tea_europe, se="ker")
```

4. Résultats par Région (suite)

Marché Asiatique

Modèle pour l'Asie

```
model_tea_asie <- rq(`Price per 100 g/ml in Euros` ~ `Launch T
                    `Private Label` + claim_sante + claim_et
                    claim_strategie + claim_naturel + packag
                    claim_bio + claim_environnement + pib_ca
data = df_tea %>%
  filter(Region_Marche == "Asie"),
  tau = c(0.25, 0.5, 0.75))

summary(model_tea_asie, se="ker")
```

4. Résultats par Région (suite)

Marché Nord-Américain

Modèle pour l'Amérique du Nord

```
model_tea_na <- rq(`Price per 100 g/ml in Euros` ~ Market + `I  
  `Private Label` + claim_sante + claim_ethi  
  claim_strategie + claim_naturel + package  
  claim_bio + claimenvironnement + pib_cate  
  data = df_tea,  
  tau = c(0.25, 0.5, 0.75))  
  
summary(model_tea_na, se="ker")
```

5. Conclusions et Recommandations

Points Clés de l'Analyse

- 1 **Différenciation Régionale** : Les déterminants de prix varient selon les régions

Recommandations Stratégiques

5. Conclusions et Recommandations

Points Clés de l'Analyse

- ❶ **Différenciation Régionale** : Les déterminants de prix varient selon les régions
- ❷ **Claims Marketing** : Impact significatif sur le positionnement prix

Recommandations Stratégiques

5. Conclusions et Recommandations

Points Clés de l'Analyse

- ❶ **Différenciation Régionale** : Les déterminants de prix varient selon les régions
- ❷ **Claims Marketing** : Impact significatif sur le positionnement prix
- ❸ **Packaging** : Matériaux et types influencent la perception de valeur

Recommandations Stratégiques

5. Conclusions et Recommandations

Points Clés de l'Analyse

- ❶ **Différenciation Régionale** : Les déterminants de prix varient selon les régions
- ❷ **Claims Marketing** : Impact significatif sur le positionnement prix
- ❸ **Packaging** : Matériaux et types influencent la perception de valeur
- ❹ **Facteurs Économiques** : PIB et production locale jouent un rôle

Recommandations Stratégiques

5. Conclusions et Recommandations

Points Clés de l'Analyse

- ❶ **Différenciation Régionale** : Les déterminants de prix varient selon les régions
- ❷ **Claims Marketing** : Impact significatif sur le positionnement prix
- ❸ **Packaging** : Matériaux et types influencent la perception de valeur
- ❹ **Facteurs Économiques** : PIB et production locale jouent un rôle

Recommandations Stratégiques

- **Segmentation** : Adapter les stratégies selon les marchés régionaux

5. Conclusions et Recommandations

Points Clés de l'Analyse

- ❶ **Différenciation Régionale** : Les déterminants de prix varient selon les régions
- ❷ **Claims Marketing** : Impact significatif sur le positionnement prix
- ❸ **Packaging** : Matériaux et types influencent la perception de valeur
- ❹ **Facteurs Économiques** : PIB et production locale jouent un rôle

Recommandations Stratégiques

- **Segmentation** : Adapter les stratégies selon les marchés régionaux
- **Positionnement** : Optimiser les claims selon les segments de prix

5. Conclusions et Recommandations

Points Clés de l'Analyse

- ❶ **Différenciation Régionale** : Les déterminants de prix varient selon les régions
- ❷ **Claims Marketing** : Impact significatif sur le positionnement prix
- ❸ **Packaging** : Matériaux et types influencent la perception de valeur
- ❹ **Facteurs Économiques** : PIB et production locale jouent un rôle

Recommandations Stratégiques

- **Segmentation** : Adapter les stratégies selon les marchés régionaux
- **Positionnement** : Optimiser les claims selon les segments de prix
- **Packaging** : Choisir les matériaux selon le positionnement prix cible

Merci pour votre attention !

Contact : [Votre email]

Ressources : - Code complet disponible dans `regquantile.R` - Données : `GNPD_tea.xlsx`, `df_pib.csv`, `df_prod_tea.csv`

Méthodes d'Estimation des Erreurs Standard

Différentes méthodes disponibles :
se = "boot" : Bootstrap (recommandé pour petits échantillons)
se = "nid" : Approximation asymptotique (moins robuste)
se = "ker" : Méthode kernel (pour grands échantillons)

Variables Utilisées dans le Modèle

- **Régionales** : Region_Marche, Market

Méthodes d'Estimation des Erreurs Standard

Différentes méthodes disponibles :
se = "boot" : Bootstrap (recommandé pour petits échantillons)
se = "nid" : Approximation asymptotique (moins robuste)
se = "ker" : Méthode kernel (pour grands échantillons)

Variables Utilisées dans le Modèle

- **Régionales** : Region_Marche, Market
- **Produit** : Launch Type, Private Label, Famille thé

Méthodes d'Estimation des Erreurs Standard

Différentes méthodes disponibles :
se = "boot" : Bootstrap (recommandé pour petits échantillons)
se = "nid" : Approximation asymptotique (moins robuste)
se = "ker" : Méthode kernel (pour grands échantillons)

Variables Utilisées dans le Modèle

- **Régionales** : Region_Marche, Market
- **Produit** : Launch Type, Private Label, Famille thé
- **Marketing** : Claims (santé, naturel, éthique, etc.)

Méthodes d'Estimation des Erreurs Standard

Différentes méthodes disponibles :
se = "boot" : Bootstrap (recommandé pour petits échantillons)
se = "nid" : Approximation asymptotique (moins robuste)
se = "ker" : Méthode kernel (pour grands échantillons)

Variables Utilisées dans le Modèle

- **Régionales** : Region_Marche, Market
- **Produit** : Launch Type, Private Label, Famille thé
- **Marketing** : Claims (santé, naturel, éthique, etc.)
- **Packaging** : Material_group, Package_group_type

Méthodes d'Estimation des Erreurs Standard

Différentes méthodes disponibles :
se = "boot" : Bootstrap (recommandé pour petits échantillons)
se = "nid" : Approximation asymptotique (moins robuste)
se = "ker" : Méthode kernel (pour grands échantillons)

Variables Utilisées dans le Modèle

- **Régionales** : Region_Marche, Market
- **Produit** : Launch Type, Private Label, Famille thé
- **Marketing** : Claims (santé, naturel, éthique, etc.)
- **Packaging** : Material_group, Package_group_type
- **Économiques** : PIB par habitant, Production de thé